
PROYECTO APLICADO

Inferencia multivariable con datos reales

Profundización en Estadística para Científicos de Datos

Segundo corte

Entrega y sustentación: Martes 7 de abril de 2026

Objetivo

El objetivo de esta actividad es aplicar los conceptos estudiados durante el segundo corte del curso, relacionados con:

- distribuciones conjuntas, marginales, condicionales
- inferencia estadística multivariable

Cada estudiante deberá desarrollar un pequeño proyecto estadístico utilizando **datos reales**, en el cual se integren exploración de datos, formulación de hipótesis y desarrollo de pruebas inferenciales.

Datos

El análisis debe realizarse sobre un conjunto de **datos reales**.

El conjunto de datos debe contener al menos:

- tres variables cuantitativas
- un número suficiente de observaciones para realizar inferencia

Preferiblemente los datos deben estar relacionados con un problema aplicado o con posibles ideas de trabajo de grado.

Preparación y limpieza de datos

Antes de realizar cualquier análisis inferencial se debe realizar un proceso de preparación de datos que incluya:

- inspección inicial del dataset
- identificación de valores faltantes
- tratamiento de observaciones atípicas
- verificación de consistencia de variables
- documentación de las decisiones tomadas

Este proceso debe ser explicado en el informe.

Análisis exploratorio

El proyecto debe incluir:

- estadísticas descriptivas
- visualización de variables
- análisis de relaciones entre variables
- interpretación de patrones observados

Además deben construirse visualizaciones conjuntas que incluyan:

- diagramas de dispersión
- análisis de dependencia entre variables
- superficies de nivel (contour plots)

Inferencia estadística

El proyecto debe incluir al menos una prueba de hipótesis multivariable sobre el vector de medias utilizando los métodos estudiados en clase.

Adicionalmente, el estudiante puede incorporar alguno de los procedimientos inferenciales descritos en los anexos, por ejemplo:

- prueba de hipótesis sobre correlación
- comparación multivariada entre grupos

En todos los casos se debe presentar:

- formulación de hipótesis
- estadístico de prueba
- distribución del estadístico
- decisión estadística
- interpretación en contexto

Informe

El proyecto debe entregarse en un documento PDF que contenga como mínimo las siguientes secciones:

1. Introducción
2. Contexto del problema
3. Descripción de los datos
4. Análisis exploratorio de datos
5. Formulación de hipótesis
6. Desarrollo del análisis estadístico
7. Resultados
8. Conclusiones
9. Referencias

Archivos a entregar

Cada estudiante deberá subir:

- informe final en PDF
- notebook o script utilizado
- conjunto de datos utilizado

- cualquier archivo necesario para reproducir el análisis

Todos los archivos deben entregarse comprimidos en un archivo .zip.

Carpeta de entrega

https://uexternadoedu-my.sharepoint.com/:f:/g/personal/julian_sanchez_uexternado_edu_co/IgB0u_W0J4XBR5XqS24q6vSPAdTn7r_4adw93jrN0bCVLzk?e=B99HZ0

Sustentación

El proyecto será sustentado en clase el **martes 8 de abril**.

Cada estudiante tendrá **5 minutos** para presentar:

- el problema analizado
- los datos utilizados
- el análisis estadístico realizado
- las conclusiones principales

Condiciones

- El trabajo es individual.
- Se evaluará principalmente la claridad del planteamiento, el rigor estadístico y la interpretación de resultados.

Rúbrica de evaluación

Criterio	Peso
Planteamiento del problema y contexto	15 %
Calidad del análisis exploratorio (EDA) y limpieza de datos	20 %
Formulación correcta de hipótesis y desarrollo inferencial	25 %
Implementación computacional y reproducibilidad del análisis	20 %
Interpretación estadística y conclusiones	10 %
Claridad del informe y presentación	10 %

ANEXO A

Pruebas sobre correlación en el contexto multivariable

Sea

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix}$$

un vector aleatorio con media

$$E(\mathbf{X}) = \boldsymbol{\mu}$$

y matriz de covarianzas

$$\Sigma = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{pmatrix}.$$

La matriz de correlaciones poblacional se define como

$$R = \begin{pmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{pmatrix}.$$

En muchos problemas de análisis de datos es de interés evaluar si dos componentes del vector aleatorio están correlacionadas.

Por ejemplo, podemos considerar la prueba

$$H_0 : \rho_{ij} = 0$$

$$H_1 : \rho_{ij} \neq 0$$

para dos variables X_i y X_j del vector multivariable.

Sea r_{ij} la correlación muestral obtenida a partir de una muestra de tamaño n .

El estadístico de prueba es

$$t = \frac{r_{ij}\sqrt{n-2}}{\sqrt{1-r_{ij}^2}}.$$

Bajo la hipótesis nula se cumple

$$t \sim t_{n-2}.$$

Ejemplo

Suponga que en un conjunto de datos se observan tres variables:

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix}$$

correspondientes, por ejemplo, a

- ingreso

- gasto
- ahorro

A partir de una muestra de tamaño

$$n = 30$$

se obtiene la matriz de correlaciones muestral

$$R = \begin{pmatrix} 1 & 0,45 & 0,30 \\ 0,45 & 1 & 0,25 \\ 0,30 & 0,25 & 1 \end{pmatrix}.$$

Si queremos evaluar si existe correlación entre X_1 y X_2 se tiene

$$r_{12} = 0,45.$$

El estadístico es

$$t = \frac{0,45\sqrt{28}}{\sqrt{1 - 0,45^2}} \approx 2,66.$$

Este valor se compara con la distribución t_{28} para decidir si se rechaza la hipótesis nula de ausencia de correlación.

ANEXO B

Comparación multivariada entre dos grupos

Suponga dos poblaciones multivariadas con vectores de medias

$$\boldsymbol{\mu}_1, \quad \boldsymbol{\mu}_2$$

y matriz de covarianzas común Σ .

Se desea evaluar

$$H_0 : \boldsymbol{\mu}_1 = \boldsymbol{\mu}_2$$

$$H_1 : \boldsymbol{\mu}_1 \neq \boldsymbol{\mu}_2.$$

Sean

$$\bar{\mathbf{X}}_1, \quad \bar{\mathbf{X}}_2$$

los vectores de medias muestrales obtenidos a partir de dos muestras de tamaño n_1 y n_2 .

Las matrices de covarianzas muestrales son

$$S_1, \quad S_2.$$

La matriz de covarianzas combinada es

$$S_p = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2}{n_1 + n_2 - 2}.$$

El estadístico de Hotelling es

$$T^2 = (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2)' \left[S_p \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \right]^{-1} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2).$$

Este estadístico puede transformarse a una distribución F mediante

$$F = \frac{(n_1 + n_2 - p - 1)}{p(n_1 + n_2 - 2)} T^2 \sim F_{p, n_1 + n_2 - p - 1}.$$

Ejemplo

Suponga que se miden dos variables

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$$

por ejemplo:

- ingreso
- consumo

en dos grupos de individuos.

Tamaños de muestra

$$n_1 = 20, \quad n_2 = 22.$$

Vectores de medias muestrales

$$\bar{\mathbf{X}}_1 = \begin{pmatrix} 50 \\ 30 \end{pmatrix}, \quad \bar{\mathbf{X}}_2 = \begin{pmatrix} 45 \\ 25 \end{pmatrix}.$$

Diferencia de medias

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 = \begin{pmatrix} 5 \\ 5 \end{pmatrix}.$$

A partir de los datos se estiman las matrices S_1 y S_2 , se calcula S_p y posteriormente el estadístico T^2 .

Este procedimiento permite evaluar si los vectores de medias de ambos grupos difieren significativamente considerando simultáneamente todas las variables.